

PROYECTO 2

Nombre: Juan Nicolás Hidalgo Parra | Pregunta 1 | Tablero.

Código: 202122726

Nombre: Gabriel Juan De Dios | Pregunta 3 | Despliegue.

Código: 202220936

Nombre: Juan Sebastián Méndez Martínez | Pregunta 2 | Tablero.

Código: 202222395

CLIENTE: Secretaría de Educación del Huila.

Objetivo: Desarrollar modelos predictivos que permitan anticipar el desempeño académico de estudiantes del Huila en las pruebas Saber 11, con el fin de orientar la inversión de recursos educativos de forma focalizada y oportuna.

Repositorio: https://github.com/nicohidalgo19/Proyecto_2.git

RESUMEN EJECUTIVO

La Secretaría de Educación del Huila enfrenta el reto de distribuir recursos educativos limitados entre 45 municipios con condiciones socioeconómicas profundamente heterogéneas. Mientras Neiva concentra la mayor población estudiantil y los mejores indicadores de acceso tecnológico, municipios como Aipe, Nátaga y Guadalupe combinan alta vulnerabilidad con los puntajes promedio más bajos del departamento. Con el fin de apoyar esta toma de decisiones de forma anticipada y basada en evidencia, se desarrollaron tres modelos predictivos basados en redes neuronales sobre los datos históricos de las pruebas Saber 11 del Huila, permitiendo estimar el desempeño académico esperado de un estudiante a partir de su perfil socioeconómico e institucional antes de que presente el examen.

El primer modelo estima el puntaje global esperado a partir de estrato, zona geográfica, nivel educativo de los padres, jornada y municipio, alcanzando un RMSE de 40.45 puntos y un R^2 de 0.27 (coherente con la literatura educativa que sitúa la influencia socioeconómica entre el 20% y el 35% del rendimiento). El segundo modelo predice si un estudiante pertenece a una jornada no convencional, logrando un AUC de 0.8369 y confirmando que estos perfiles son estructuralmente predecibles. El tercer modelo clasifica si un estudiante quedará bajo el promedio departamental: un perfil rural de estrato 1 sin acceso a tecnología obtuvo una probabilidad del 72.8%, frente al 17.7% de un estudiante urbano de estrato 5 en Neiva, evidenciando que el rendimiento académico depende más del entorno que de las características individuales.


Los tres modelos fueron integrados en un tablero interactivo en Dash, desplegado en AWS mediante contenedores Docker, que permite simular perfiles y obtener predicciones en tiempo real sin conocimientos técnicos. Cada pestaña presenta formularios de entrada, un gauge contextualizado frente al promedio departamental y una recomendación accionable automática, haciendo del tablero un instrumento accesible para tomadores de decisión.

Los hallazgos convergen en un diagnóstico claro: la desigualdad educativa en el Huila tiene raíces estructurales anticipables y, por tanto, prevenibles. Se recomienda priorizar la inversión en conectividad rural, fortalecer las jornadas nocturna y sabatina, y concentrar el acompañamiento en los municipios de mayor vulnerabilidad. Los tres modelos operan de forma complementaria como un sistema de alerta temprana que permite identificar, clasificar e intervenir sobre el riesgo académico antes de que se materialice en los resultados del examen.

PREGUNTA 1

Responsable: Juan Nicolás Hidalgo

¿Cuál es el puntaje global esperado de un estudiante dado su estrato socioeconómico, zona geográfica (urbano/rural), nivel educativo de los padres y jornada escolar?




Se desarrolló un modelo de regresión basado en red neuronal para estimar el puntaje global esperado de un estudiante del Huila en las pruebas Saber 11, a partir de su perfil socioeconómico e institucional. Las variables predictoras incluyen estrato, zona geográfica, nivel educativo de los padres, jornada escolar, municipio, acceso a internet y computador, naturaleza del colegio y género. Los puntajes por área fueron excluidos deliberadamente para evitar data leakage, dado que son componentes directos del puntaje global. Se evaluaron cuatro arquitecturas de red neuronal con la misma base de entrenamiento y prueba (80/20).

Los resultados se registraron mediante MLflow:

Modelo	RMSE (pts)	MAE (pts)	R ²	Resultado
Modelo Base	40,454	32,459	0,274	SELECCIONADO
Modelo Profundo	40,471	32,472	0,274	Descartado
Modelo Dropout	40,811	32,780	0,262	Descartado
Modelo Simple LR	40,509	32,498	0,272	Descartado

El Modelo Base — arquitectura Input → Dense(32, ReLU) → Dense(16, ReLU) → Salida lineal, optimizador Adam con lr = 0.0001 — obtuvo el mejor desempeño con un RMSE de 40.45 puntos y un R² de 0.2744. Los modelos más complejos no aportaron mejoras: la Red Profunda presentó inestabilidad en la validación, y el Dropout penalizó el aprendizaje sin reducir sobreajuste, dado que el modelo base no lo exhibía.



El R² de 0.27 indica que el modelo explica el 27.5% de la variabilidad del puntaje global usando exclusivamente variables socioeconómicas. Este resultado es coherente con la literatura educativa, que estima que el contexto socioeconómico explica entre el 20% y el 35% del rendimiento cuando no se incluyen variables pedagógicas directas. El diagrama de dispersión confirma que el modelo captura correctamente la tendencia general, aunque con dispersión residual atribuible a factores no observados como calidad docente y motivación individual.

Para la Secretaría, el modelo permite simular el impacto de intervenciones concretas — mejorar conectividad, cambiar de jornada — sobre el puntaje esperado de un estudiante con un perfil dado, complementando el análisis descriptivo del Proyecto 1 con capacidad predictiva cuantitativa.

PREGUNTA 2

Responsable: Juan Sebastián Méndez

¿Es posible predecir si un estudiante asiste a una jornada no convencional (nocturna o sabatina) a partir de su perfil socioeconómico y municipio?

Se desarrolló un modelo de clasificación binaria para poder predecir, a partir de un perfil socioeconómico del estudiante, si pertenece a una jornada no convencional (nocturna o sabatina) o a una jornada convencional (completa, mañana, tarde, o única).

Datos utilizados

El modelo se entrenó sobre 100.360 registros después de eliminar los registros nulos. Se usaron 9 variables en total para un perfil socioeconómico: estrato, zona del colegio, nivel educativo de la madre, nivel educativo del padre, municipio, acceso, acceso a internet, acceso a computador, naturaleza del colegio, y género. Los puntajes se excluyeron ya que se consideró que estas variables no presentaban ningún aporte para un perfil socioeconómico del estudiante. La variable objetivo se construyó agrupando las jornadas (Nocturna y Sabatina) en la clase 1 (19.9% del total) frente a las jornadas regulares como clase 0 (80.1%)

Modelos: Se evaluaron 4 modelos sobre una misma partición 80/20 de datos.

Modelo	Arquitectura	AUC-ROC	Resultado
Modelo Base	32 → 16 → <i>Sigmoide</i>	0.8331	Descartado
Modelo Profundo	64 → 32 → 16 → <i>Sigmoide</i>	0.8336	Descartado
Modelo Dropout	64 → Dropout → 32 → Dropout → Sigmoide	0.8369	SELECCIONADO
Modelo Simple LR	32 → 16 → <i>Sigmoide</i> (LR = 0.0001)	0.8322	Descartado

Se seleccionó el modelo con Dropout ya que este reportaba el mejor AUC (0.8369) indicando que el modelo distingue correctamente entre jornadas convencionales y no convencionales en el 84% de los casos. Además, analizando el modelo concluimos que el Dropout fue beneficioso ya que al tener clases desbalanceadas este actuaba como regulizador que impide que la red memorice patrones de la clase convencional.



Los 2 perfiles evaluados pertenecen al mismo municipio y estrato, sin embargo, el modelo los clasifica de manera diferente: El primero con un 7.4% de probabilidad de jornada no convencional y el segundo con un 71.1% de probabilidad. Esta diferencia revela que el modelo está capturando correctamente las variables que diferencian a los estudiantes.

Con esta herramienta la secretaria de educación del Huila podrá transformar datos en decisiones clave, anticipar antes de reaccionar, y focalizar recursos. Con esta herramienta la secretaria podrá identificar que estudiantes tienen mayor riesgo de desplazarse o estar en jornadas no convencionales y focalizar los recursos necesarios para prevenir dichos sucesos. Además, con dicha prevención la secretaria puede enfocarse en responder preguntas como: ¿En cuáles municipios se concentran los estudiantes de mayor riesgo?, ¿Vale más invertir en conectividad rural o en transporte escolar?, y ¿Qué perfil de estudiante debería recibir un subsidio primero?, así se puede dirigir un recurso limitado a perfiles que más lo necesiten.

PREGUNTA 3

Responsable: Gabriel Juan De Dios

¿Un estudiante estará por debajo del promedio departamental dado su perfil socioeconómico y municipio?



Los hallazgos indican que variables como el contexto social, familiar y territorial influyen en el rendimiento académico de los estudiantes en el departamento del Huila. La comparación de los perfiles del modelo ilustra una diferencia sustancial en la clasificación.


En el primer caso, correspondiente a un estudiante clasificado en condiciones socioeconómicas vulnerables, se observó una probabilidad del 72.8% de estar por debajo del promedio departamental. Este perfil se basa en el estrato 1, que reside en una zona rural, estudia en una escuela no oficial, no tiene computadora en casa y un bajo nivel educativo en los padres. Además, el municipio de Colombia (Huila) históricamente exhibe mayores niveles socioeconómicos de vulnerabilidad utilizando medidas del DANE, subrayando los riesgos académicos descubiertos por el modelo. El segundo tipo de perfil solo tenía una probabilidad del 17.7% de estar por debajo del promedio (llamado "por encima del promedio"). El estudiante está en el estrato 5, reside en un área urbana, tiene acceso a internet y computadora, ambos padres tienen posgrado, y vive en Neiva, municipio con mayor desarrollo económico, infraestructura y oportunidades educativas dentro del departamento. Estos hallazgos indican que el rendimiento académico del estudiante no depende únicamente de características individuales, también señalan el entorno social y geográfico en el que el estudiante está creciendo. Factores como el acceso a la tecnología, el nivel educativo de los padres, la residencia rural y la diferencia en los municipios parecen ser variables que hacen que la predicción en el modelo sea significativa.

El modelo también representa una ayuda para el Departamento de Educación del Huila en la detección temprana de estudiantes con alto riesgo académico. También permitiría dirigir esfuerzos de intervención a municipios y personas vulnerables a través de programas de conectividad, mejorar el apoyo escolar, el apoyo pedagógico y la racionalización del uso de recursos. Por último, aunque el modelo no es un sustituto del análisis pedagógico y social que realizan las instituciones educativas, proporciona una base analítica útil para decisiones basadas en datos y, por lo tanto, sirve para reducir las brechas en la educación en el departamento del Huila.

TABLERO DE DATOS

Responsable: Juan Nicolás y Juan Sebastián

El tablero fue desarrollado en Dash (Python) y desplegado en AWS, permitiendo a la Secretaría de Educación del Huila interactuar con los tres modelos predictivos del proyecto mediante una interfaz accesible y sin requerir conocimientos técnicos.



Diseño y estructura. El tablero se organizó en tres pestañas, una por pregunta de negocio. En la parte superior se presentan tres KPIs fijos (promedio global departamental, municipios analizados y total de estudiantes) que ofrecen contexto inmediato al usuario. Se adoptó un esquema visual oscuro con tipografía clara y elementos de acento en azul cian, buscando legibilidad y coherencia visual. Cada pestaña sigue el mismo patrón: formulario de entrada a la izquierda y panel de resultados a la derecha, facilitando la navegación y reduciendo la curva de aprendizaje del usuario.

Flujo de uso. El usuario selecciona el perfil del estudiante mediante menús desplegables (estrato, zona geográfica, nivel educativo de los padres, municipio, acceso a tecnología, entre otros) y presiona Predecir o Clasificar. El resultado se presenta con tres elementos: el valor o clasificación predicha, un gauge que ubica el resultado frente al promedio departamental, y un texto de interpretación automática con recomendación accionable para la Secretaría. El botón Limpiar restablece el formulario para una nueva consulta.

Decisiones técnicas. Los modelos se cargan pre-entrenados desde archivos serializados (.keras y .pkl) al iniciar el servidor, eliminando tiempos de espera por reentrenamiento en cada predicción. Los callbacks de Dash manejan predicción y limpieza en un único bloque por modelo. El pipeline de transformación — escalamiento con StandardScaler y target encoding de municipio — se replica con los mismos transformadores usados en el entrenamiento, garantizando consistencia entre el notebook y el tablero.



ROL DESPLIEGUE Y MANTENIMIENTO

Responsable: Gabriel Juan De Dios

1. Configuración de la instancia EC2:

Nombre: dash-icfes11 | **AMI:** Ubuntu Server 24.04 LTS (HVM) SSD | **tipo:** t2.medium | **llave:** llaveicfes.pem

Puertos abiertos: 22 (SSH) y 8050 (Custom TCP) -> Anywhere IPv4 | **Almacenamiento:** 30 GB

2. Archivos clave y Dockerfile:

Se crearon dos archivos en la carpeta del proyecto junto a *app.py* y la carpeta modelos/:

- **Requiere.txt:** dash, pandas, numpy, plotly, joblib, TensorFlow==2.16.1, gunicorn, scikit-learn
- **Dockerfile:** define la imagen del contenedor con los siguientes comandos principales:
 - FROM python:3.11-slim* → imagen base ligera de Python
 - RUN apt-get install libgomp1* → dependencia del sistema para TensorFlow
 - COPY + RUN pip install* → copia e instala todas las dependencias
 - EXPOSE 8050* → abre el puerto de la aplicación
 - CMD gunicorn --bind 0.0.0.0:8050 app:server* → lanza la app en producción

Nota: Se agregó *server = app.server* en *app.py* para exponer el servidor WSGI a Gunicorn.

3. Despliegue:

Tras instalar Docker en la instancia y transferir los archivos con SCP, se ejecutaron:

```
sudo docker build -t mi-dash-app:latest /home/ubuntu/
```

```
sudo docker run -d -p 8050:8050 --name dash-app mi-dash-app:latest
```

4. Evidencia del funcionamiento:

```
ubuntu@ip-172-31-42-15:~$ sudo docker run -d -p 8050:8050 --name dash-app mi-dash-app:latest
3931882d3ae9d31975cc6c02d5a34b82ec2fe0a38376bce424fec253ec1f4cf4
ubuntu@ip-172-31-42-15:~$ sudo docker logs dash-app
[2026-05-25 21:02:07 +0000] [1] [INFO] Starting gunicorn 26.0.0
[2026-05-25 21:02:07 +0000] [1] [INFO] Listening at: http://0.0.0.0:8050 (1)
[2026-05-25 21:02:07 +0000] [1] [INFO] Using worker: sync
[2026-05-25 21:02:07 +0000] [7] [INFO] Booting worker with pid: 7
[2026-05-25 21:02:08 +0000] [1] [INFO] Control socket listening at /root/.gunicorn/gunicorn.ctl
```

Figura 1: Logs del contenedor: Gunicorn arrancando en puerto 8050.




Figura 2: Aplicación accesible del dash.