

1. Descripción general

El objetivo de este proyecto es desarrollar un producto de analítica de datos sobre los resultados de las pruebas Saber 11 en el país. Para desarrollar este producto usted debe hacer uso de los **mismos datos empleados en el proyecto 1**. Identifique un usuario final que puede estar interesado en un producto de analítica basado en estos datos y diseñe su producto pensando especialmente en ese usuario. Esto quiere decir que su desarrollo debe ser completo, pero debe estar especialmente enfocado en los intereses de este usuario. El nivel esperado de desarrollo de este producto es de **prototipo funcional**.

2. Roles

Para la realización de este proyecto se han contemplado los siguientes roles:

1. Ciencia de datos (x3).
2. Análisis de negocio (x3).
3. Tablero de datos (x2).
4. Despliegue y mantenimiento.

Cada miembro del grupo debe tener 3 roles (análisis de negocio, ciencia de datos, otro) y realizar las tareas asociadas a estos roles. Cada miembro debe:

1. Tomar el rol de análisis de negocio y responder por una pregunta de negocio.
2. Tomar el rol de ciencia de datos y desarrollar los modelos necesarios para responder a su pregunta de negocio.
3. Tomar uno de los tres roles restantes (tablero de datos, despliegue y mantenimiento).

La calificación de cada miembro del equipo estará asociada a las tareas específicas de los roles tomados y al resultado global del proyecto. **Los roles de cada miembro del equipo deben ser diferentes a los seleccionados en el proyecto 1**, excepto el rol de análisis de negocio.

Si un estudiante realiza un rol que ya realizó en el proyecto anterior, su nota será cero en ese rol.

3. Comprensión de negocio y datos: preguntas de negocio y plan de acción

Tarea 1

Determine **tres preguntas** de negocio que quiere resolver para su cliente seleccionado (una pregunta por cada científico de datos). Identifique cómo puede resolver estas preguntas a través de modelos predictivos de clasificación o regresión basados en **redes**

neuronales (puede incluir modelos *adicionales* si lo considera pertinente). Debe haber por lo menos un modelo de regresión y uno de clasificación.

Roles involucrados: Análisis de negocio, Ciencia de datos.

Tarea 2 - Selección, limpieza y alistamiento de datos

Para desarrollar este producto usted debe hacer uso de los datos disponibles en el portal de Datos Abiertos: <https://www.datos.gov.co/Educaci-n/Resultados-nicos-Saber-11/kgxf-xxbe> (note que los datos están actualizados a abril de 2024). Emplee el mismo subconjunto de datos asignado para el proyecto 1 del curso. Se espera que ya cuente con sus datos listos del proyecto anterior.

Roles involucrados: Ciencia de datos.

Tarea 3 - Exploración de datos

Retome el análisis exploratorio realizado en el primer proyecto.

Roles involucrados: Ciencia de datos.

4. Modelos

Tras explorar en detenimiento los datos y tener claras las preguntas de negocio, es hora de pasar a construir los modelos. Se espera que sean modelos de regresión y clasificación basados en redes neuronales. Tenga presente lo aprendido en la exploración de datos, así como el usuario final seleccionado y las preguntas a resolver.

Tarea 4 - Modelamiento

Aquí deberá explorar diferentes configuraciones de modelo, realizar ingeniería de características, emplear diferentes métodos de estimación, comparar y seleccionar las mejores alternativas. Consulte bibliografía que le permita contar con elementos para proponer los modelos. No es necesario emplear todas las variables disponibles, pero todas las variables incluidas y sus relaciones deben estar correctamente justificadas. Como hay un buen número de variables, clientes y preguntas de negocio diferentes, se espera que los modelos desarrollados por cada equipo sean **únicos**. Evalúe su modelo usando métricas apropiadas. **Documente el modelamiento realizado y sus experimentos empleando MLflow.**

Roles involucrados: Ciencia de datos.

5. Producto y evaluación

El producto debe ser un tablero en Dash desplegado en la nube de AWS, usando contenedores Docker. El tablero debe ser de fácil uso y le debe permitir al usuario **interactuar** con los modelos predictivos desarrollados. Puede tomar el tablero del proyecto 1 como base, pero solo se evaluarán los componentes asociados a los modelos predictivos.

Tarea 5 - Diseño y desarrollo del tablero

Empiece por diseñar el tablero: ¿qué valores debe permitir ingresar? ¿qué resultados genera? ¿cómo mostrará las instrucciones? ¿cómo dispondrá estos elementos en el tablero? Para esta tarea es buena idea hacer un wireframe (un diseño sencillo que puede hacer en papel o digitalmente), que le permite tener una visión clara de su tablero y todos sus elementos. Recuerde no perder de vista al usuario y su necesidad. Piense siempre en la experiencia del usuario. Una vez haya terminado el diseño, desarrolle su tablero en Dash.

Roles involucrados: Tablero de datos.

Tarea 6 - Evaluación

Evalúe los resultados, considerando las preguntas de negocio, los *insights* obtenidos del análisis descriptivo, los modelos predictivos y el tablero desarrollado.

Roles involucrados: Análisis de negocio, Ciencia de datos, Tablero de datos.

Lidera: Análisis de negocio.

Tarea 7 - Despliegue y mantenimiento

El tablero debe quedar desplegado en la nube empleando contenedores Docker en AWS. Además, los **modelos** que se desplieguen deben estar **serializados** en archivos. Es decir, al ejecutar su tablero los modelos se deben cargar pre-entrenados de archivos locales. Asegúrese de que su tablero sea accesible y quede en ejecución.

Roles involucrados: Despliegue y mantenimiento.

6. Entregables

Como resultado de las tareas anteriores deberá entregar los siguientes resultados y soportes:

1. Resultado 1: reporte de **máximo 6 páginas** con la documentación de las tareas, los resultados principales del análisis exploratorio de datos y la modelización. Cada sección del proyecto debe indicar qué rol y miembro del equipo la realizó. El reporte debe describir cada tarea listada en el reporte. Las 6 páginas se deben dividir así:
 - Una página inicial con un resumen ejecutivo que incorpore los hallagos principales del proyecto.
 - Una página para cada pregunta de negocio, su modelo y su evaluación.
 - Una página para describir los elementos principales del tablero.
 - Una página para describir el ambiente de despliegue y mantenimiento en el que se encuentra el producto final.

2. Resultado 2: presentación de **máximo 10 minutos** con los resultados principales del proyecto, donde cada integrante debe presentar los resultados asociados a su rol. Esta presentación debe incluir también un espacio para demostrar el tablero desarrollado.
3. Resultado 3: tablero desarrollado en Dash y desplegado en la nube.
4. Reporte de trabajo en equipo: incluya un pequeño reporte (máximo una página) de cómo se dividieron los roles entre los miembros del equipo.
5. Soporte 1: análisis de negocio (soporte incluido en el reporte).
6. Soporte 2: fuentes de de análisis y modelización (cuadernos de jupyter o archivos .py con la modelización desarrollada). Aquí debe incluir los pasos de entrenamiento y prueba del modelo, así como los pantallazos de MLflow con los resultados de los experimentos realizados (pueden ir en un documento o en una carpeta de su repositorio).
7. Soporte 3: fuentes del tablero (archivos .py del tablero desarrollado).
8. Soporte 4: snapshots de los recursos lanzados para el despliegue (AWS y terminal), y URL del tablero en ejecución.
9. Soporte 5: **repositorio Git** en Github, con un historial de commits que claramente refleje el aporte de cada miembro del grupo (de acuerdo con su rol). El repositorio debe estar estructurado con carpetas que reflejen cada una de las tareas definidas en el proyecto. Debe incluir una **carpeta “despliegue”** que contenga la última versión del tablero y permita lanzarlo, replicando el despliegue en AWS, incluyendo un archivo Dockerfile.

Nota: los soportes son parte fundamental de la entrega. Su no entrega lleva a una alta penalización.

Nota 2: si bien el trabajo es en equipo (de 2 o 3 personas), la nota es individual, luego es necesario que cada miembro del equipo demuestre su contribución al proyecto, tanto a través de los **commits en el repositorio**, como a través del **reporte** de trabajo en equipo y la **sustentación**.

La calificación individual del proyecto se realizará de la siguiente manera:

1. **25 puntos:** contribución individual al reporte.
2. **25 puntos:** contribución individual a la presentación.
3. **50 puntos:** contribución individual de acuerdo con su rol, reflejado en los entregables y soportes asociados.

7. Recomendaciones

1. El objetivo del proyecto es lograr un buen producto, bien soportado y claramente desarrollado. Justifique adecuadamente sus decisiones, observaciones y conclusiones.
2. Sea conciso y eficiente con el espacio. Ni el reporte ni la presentación deben ser largos. Al contrario, en un buen reporte cada gráfica y afirmación importa, y en una buena presentación cada diapositiva cuenta.
3. Es un trabajo en equipo. Defina los ítems de trabajo, asígnelos entre los miembros del equipo, defina fechas de entrega y revisión interna. Discuta los resultados, observaciones y conclusiones. Priorice tareas y resultados a incluir.
4. Empiece a trabajar prontamente y discuta con el instructor su avance y resultados.

Fecha de entrega: lunes 25 de mayo de 2026